

Bericht zur Werkstudententätigkeit

SAP SE – Product & Engineering – User Research

Tätigkeitszeitraum: 01.10. 2024 – 30.09.2025 (12 Monate, insg. 597,5 Stunden)

Allgemeine Info

Ich habe als Werkstudentin im Bereich User Research bei SAP gearbeitet. SAP ist ein Softwareunternehmen und entwickelt insbesondere Unternehmenssoftware. Ich war im Geschäftsbereich Mobile Apps tätig, der mobile Anwendungen für verschiedene Geschäftsprozesse entwickelt.

Die Aufgabe meines Teams bestand darin, das Verhalten und die Anforderungen der Nutzer dieser Apps zu untersuchen. Ziel war es, Erkenntnisse über die Nutzung der Produkte zu gewinnen und damit Entscheidungen für Verbesserungen und die Weiterentwicklung zu ermöglichen. Dazu arbeiteten wir insbesondere mit Produktmanagern, Softwareentwicklern und UX-Designern zusammen.

Neben qualitativen Methoden wie Nutzerinterviews und Kundenworkshops, wurden bei mir im Team hauptsächlich quantitative Online-Studien durchgeführt. Dafür erstellten wir Fragebögen, die zum Teil auch interaktive Prototypen beinhalteten, an denen die Teilnehmer Aufgaben lösen mussten. Ich war an Planung, Durchführung und Auswertung der Studien beteiligt.

Tätigkeiten

Programmierung von Python-Skripten zur Datenaufbereitung

Zu meinen Aufgaben gehörte die Entwicklung von Python-Skripten zur Automatisierung verschiedener Datenaufbereitungs- und Datenqualitätsprüfungsroutinen. Dazu zählte beispielsweise die Umkodierung von Lickert-Skalen, da die Antworten in dem verwendeten Befragungstool zunächst als Textwerte und nicht als numerische Variablen gespeichert wurden. Außerdem wurden „Speeder“ (Teilnehmer, die den Fragebogen in auffällig kurzer Zeit bearbeiteten) identifiziert und entfernt. Zusätzlich wurden Teilnehmer entfernt, die durch einheitliches Antwortverhalten (z. B. wiederholtes Auswählen derselben Skalenstufe) oder durch falsch beantwortete Kontrollfragen („Bitte wählen Sie Antwortoption 2“) auffielen. Für einige Studien war außerdem eine Zusammenführung verschiedener Datensätze erforderlich.

Statistische Auswertung von Studiendaten

Zur Auswertung der Daten wurden deskriptive Statistiken, z.B. arithmetisches Mittel, Standardabweichungen und Minimal-/Maximalwerte berechnet. Für die Präsentation gegenüber Stakeholdern erstellte ich Visualisierungen, z.B. Balkendiagramme, Kreisdiagramme oder Scatterplots.

Außerdem wurden regelmäßig A/B-Tests durchgeführt. Dabei wurden die Studienteilnehmender randomisiert einer von zwei Gruppen zugeordnet. Die Gruppen bekamen dann unterschiedliche App-Prototypen gezeigt, die sie testen sollen, um danach eine Bewertung zu verschiedenen Metriken, z.B. der wahrgenommene Benutzerfreundlichkeit, ihrer Zufriedenheit oder ihrer zukünftigen Nutzungsabsicht auf 5- oder 7-stufigen Lickert-Skalen abzugeben. Zusätzlich wurden Nutzungsmetriken wie die Bearbeitungszeit, Klickanzahl oder die Erfolgsquote erfasst. Die Ergebnisse der beiden Gruppen wurden durch Signifikanztests miteinander verglichen. Je nach Skalenniveau führte ich etwa t-Tests (z.B. für die Anzahl Klicks) oder Mann-Whitney-U-Tests (für die Lickert-Skalen) durch.

Zudem wurden für einige der genannten Metriken Korrelationen berechnet, z.B. um zu prüfen, ob es einen Zusammenhang zwischen Zufriedenheit und Nutzungsabsicht gibt.

Zeitreihendaten App-Feedback

Außerdem werteten wir In-App-Feedback einiger Apps aus. Die Nutzer konnten ihre Nutzererfahrung auf einer Skala von 1-5 bewerten. Die Auswertung erfolgte wöchentlich. Zur Glättung kurzfristiger Schwankungen wurden gleitende Mittelwerte berechnet. Die Bewertungen vor und nach der Veröffentlichung neuer App-Versionen wurden miteinander verglichen, um zu untersuchen, ob Updates zu Veränderungen der Nutzerbewertungen führten. Die Ergebnisse wurden in Zeitreihendiagrammen visualisiert.

Clustering zur Identifikation von Nutzergruppen

Als eine bestehende App neugestaltet werden sollte, sollten zunächst Nutzergruppen definiert werden, damit in künftigen Studien nach diesen differenziert werden könnte. Dafür wurden Nutzungsdaten von über 1000 Nutzern über einen Zeitraum von einem Monat erfasst und ausgewertet. Dazu gehörten z.B. die Nutzungshäufigkeit einzelner Funktionen, die Verweildauer in verschiedenen Bereichen der App sowie weitere Interaktions- und Eingabedaten.

Zur Identifikation von Nutzergruppen wurde *k*-Means-Clustering eingesetzt. Es wurde angenommen, dass es drei Nutzergruppen gäbe (Intensivnutzer, regelmäßige Nutzer und Gelegenheitsnutzer). Die Elbow-Methode stütze die Wahl von drei Clustern, da eine höhere Anzahl an Clustern keine wesentliche Verbesserung der Clusterlösung ergab. Anschließend wurde untersucht, welche Nutzungsmerkmale sich besonders stark zwischen den gebildeten Clustern unterschieden und einige besonders charakteristische Eigenschaften ausgewählt. Diese wurden in folgenden Studien abgefragt, um die Teilnehmer in eine der drei Gruppen einzuordnen und die Ergebnisse differenziert auswerten zu können.

Pilotprojekt zur Evaluierung der Kategorisierung offener Angaben mit Large Language Models (LLMs)

Im Rahmen der Einführung einer unternehmenseigenen KI wurden mögliche Anwendungsfälle für den Tätigkeitsbereich evaluiert. Als erster Use Case wurde die automatisierte Kategorisierung offener Angaben untersucht, die bisher manuell durchgeführt wurde.

Hierfür wurde zunächst eine Zufallsstichprobe aus mehreren Feldern mit offenen Textangaben gezogen und die Daten randomisiert. Anschließend kategorisierten eine weitere Werkstudentin und ich die Angaben unabhängig voneinander und entwickelten auf dieser Grundlage ein Kategoriensystem. Zur Überprüfung der Übereinstimmung zwischen den manuellen Kodierungen wurde die Intercoder-Reliabilität mithilfe von Cohen's Kappa berechnet.

Im nächsten Schritt wurde das entwickelte Kategoriensystem dem LLM zur Verfügung gestellt, welches die offenen Angaben automatisiert kategorisierte. Zur Bewertung der Modellgüte wurden die automatisierten Kategorisierungen mit den manuell erstellten Referenzkategorien verglichen und Precision sowie Recall berechnet. Die Ergebnisse der Evaluation wurden anschließend an ein Entwicklerteam weitergegeben, welches auf dieser Grundlage Anpassungen am LLM vornahm.

Bezug zu Studiengang

Die im Masterstudiengang Survey-Statistik und Datenanalyse erworbenen Kenntnisse konnte ich während meiner Tätigkeit im Bereich User Research direkt anwenden und durch praktische Erfahrungen erweitern. Besonders relevant waren dabei die Inhalte aus den Bereichen Datenerhebung, statistische Analyse und Datenvisualisierung. Kenntnisse über Fragebogenkonstruktion, Skalenniveaus und statistische Auswertungsmethoden unterstützten mich dabei, erhobene Nutzerdaten kritisch zu beurteilen und geeignete Analysen durchzuführen.

Zu den angewendeten Methoden gehörten beispielsweise deskriptive Analysen, Hypothesentests zum Vergleich von Nutzergruppen sowie k -Means-Clustering. Auch meine Programmierkenntnisse in Python aus dem Studium konnte ich für die Datenaufbereitung, Analyse und Visualisierung einsetzen. Besonders die Kommunikation statistischer Ergebnisse für ein nicht-statistisches Publikum war eine wertvolle Ergänzung zum Studium.

Bewertung

Meine Tätigkeit im User Research war eine sehr positive und lehrreiche Erfahrung. Besonders wichtig war für mich die Möglichkeit, die im Studium erworbenen statistischen Kenntnisse in einem praktischen Anwendungskontext einzusetzen und den gesamten Prozess von der Planung einer Studie über die Datenerhebung bis zur Auswertung zu begleiten. Im Gegensatz zum Studium, in dem hauptsächlich bereits vorliegende Datensätze analysiert werden, konnte ich dabei auch Erfahrungen in der Erhebung von Daten sammeln.

Neben meinen fachlichen Fähigkeiten konnte ich auch wichtige Soft Skills weiterentwickeln. Dazu gehörten insbesondere die Kommunikation mit verschiedenen Stakeholdern sowie die verständliche Vermittlung statistischer Ergebnisse an Personen ohne statistischen Hintergrund. Da User Research an der Schnittstelle von Design, Informatik und Datenanalyse stattfindet, war es häufig notwendig, unterschiedliche Perspektiven und Prioritäten zusammenzubringen.

Durch die Tätigkeit bei SAP konnte ich außerdem Einblicke in die Arbeitsweise eines großen, international agierenden Unternehmens gewinnen. Da die Kommunikation im Team überwiegend auf Englisch erfolgte, bin ich deutlich sicherer im Sprechen von Englisch im beruflichen Kontext geworden.

Besonders interessant fand ich die Verbindung zwischen methodischem Anspruch und praktischer Anwendung. Während meine Teamleiterin großen Wert auf eine statistisch saubere Durchführung und Interpretation der Studien legte, standen für Produkt- und Designteams häufig vor allem konkrete Handlungsempfehlungen im Vordergrund. Dadurch habe ich gelernt, dass statistische Analysen im Unternehmenskontext nicht nur methodisch korrekt sein müssen, sondern auch verständlich kommuniziert und in den jeweiligen Entscheidungsprozess eingeordnet werden müssen.